

ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



BLM 4504
Sayısal Görüntü İşleme
Vize Raporu

COVID-19 Tespiti için Göğüs Röntgen Görüntülerinin Analizi

Doğukan Çakır (23291742)

Ece İrem Şişer (22290727)

Assistant Prof. Dr. Feyza TOKTAŞ

Tarih
(Nisan, 2026)

ÖZET

Bu çalışma, göğüs röntgeni (X-ray) görüntüleri üzerinden COVID-19 hastalığının hızlı ve güvenilir teşhisi için üç farklı metodolojik yaklaşımın karşılaştırmalı analizini sunmaktadır. Araştırma kapsamında, 21.165 görüntüden oluşan kapsamlı “COVID-19 Radiography Database” kullanılmıştır. Çalışmanın metodolojisi; geleneksel görüntü işleme tabanlı **Otsu’s Thresholding** (Eşikleme), öznetelik çıkarımı odaklı klasik makine öğrenmesi (**HOG/LBP + SVM**) ve transfer öğrenme tabanlı derin öğrenme (**DenseNet201**) mimarilerinden oluşmaktadır. Yöntemlerin başarısı; **Doğruluk (Accuracy)**, **Hassasiyet (Sensitivity/Recall)**, **Kesinlik (Precision)** ve **F1-Skoru** metrikleri üzerinden değerlendirilerek tıbbi teşhis süreçlerinde “false negative/yanlış negatif” oranını minimize eden en optimum klinik karar destek yapısının belirlenmesi hedeflenmektedir. Elde edilecek sonuçların, radyologların iş yükünü azaltma ve erken teşhis süreçlerini hızlandırma potansiyeli tartışılacaktır.

İÇİNDEKİLER

ÖZET.....	iii
İÇİNDEKİLER.....	iv
1. GİRİŞ	1
1.1. Problem Tanımı.....	1
1.2. Çalışmanın Amacı.....	2
1.3. Çalışmanın Kapsamı	2
1.4. Kabuller ve Sınırlılıklar.....	2
2. LİTERATÜR TARAMASI.....	4
2.1. Makale İncelemeleri.....	4
2.2. İleri Seviye Derin Öğrenme ve Güvenilirlik Stratejileri	7
2.3. Evrimsel Sinir Ağları (CNN) ve Transfer Öğrenme Yaklaşımları.....	7
2.4. Hibrit Yöntemler ve Doku Analizi.....	7
2.5. Klinik Perspektif ve Komplikasyon Yönetimi	8
2.6. Literatürün Genel Değerlendirmesi ve Sentezi	8
2.7. Literatür Sentez Tablosu	8
3. METODOLOJİ.....	10
3.1. Veri Seti Tanımı ve Hazırlığı	10
3.2. Önerilen Yöntemler.....	11
3.3. Performans Değerlendirme Metrikleri (Evaluation Metrics)	11
4. KAYNAKÇA	13
EKLER	14
EK 1. Veri Seti Kaynakları ve Teknik Spesifikasyonlar.....	15
1.1. Veri Seti İçin Zorunlu Akademik Atıflar	15
1.2. Ham Veri Depoları ve Kaynak Linkler	15
1.3. Teknik Veri Özellikleri	16

1. GİRİŞ

COVID-19, 2019 yılının sonlarında ortaya çıkan ve kısa sürede küresel bir salgın haline gelen bulaşıcı bir solunum yolu hastalığıdır. Hastalığın hızlı yayılımı, sağlık sistemleri üzerinde ciddi baskı oluşturmuş ve erken teşhisin önemini artırmıştır. COVID-19'un doğru ve hızlı bir şekilde teşhis edilmesi, hem hastalığın yayılmasını kontrol altına almak hem de uygun tedavi sürecinin başlatılması açısından kritik bir öneme sahiptir.

Günümüzde COVID-19 teşhisinde en yaygın kullanılan yöntem RT-PCR testidir. Ancak bu yöntem bazı dezavantajlara sahiptir. Test süresinin uzun olması, maliyetli olması ve bazı durumlarda yanlış negatif sonuçlar vermesi, alternatif teşhis yöntemlerine olan ihtiyacı artırmıştır. Bu noktada tıbbi görüntüleme yöntemleri önemli bir alternatif olarak ortaya çıkmaktadır.

Akciğer X-ray görüntüleri, COVID-19'un akciğerlerde oluşturduğu hasarın gözlemlenmesine olanak tanımaktadır. Bu görüntüler düşük maliyetli olmaları, hızlı sonuç vermeleri ve yaygın olarak kullanılmaları nedeniyle avantaj sağlamaktadır. Ancak bu görüntülerin doğru yorumlanması uzmanlık gerektirmektedir.

Son yıllarda yapay zekâ teknolojilerinin gelişmesiyle birlikte, özellikle Convolutional Neural Network (CNN) tabanlı yöntemler görüntü işleme alanında önemli başarılar elde etmiştir. Bu yöntemler sayesinde tıbbi görüntülerden anlamlı bilgiler çıkarılabilmekte ve hastalık teşhisi yapılabilmektedir.

1.1. Problem Tanımı

COVID-19'un hızlı ve doğru bir şekilde tespit edilmesi, salgının kontrol altına alınması açısından büyük önem taşımaktadır. Ancak mevcut teşhis yöntemleri her zaman yeterli olmamaktadır. RT-PCR testlerinin uygulanma süresi ve erişilebilirlik sorunları, alternatif yöntemlerin geliştirilmesini zorunlu hale getirmiştir.

Akciğer X-ray görüntülerinin değerlendirilmesi uzmanlık gerektiren bir süreçtir ve yoğun hasta yükü altında hatalar meydana gelebilmektedir. Bu durum, otomatik teşhis sistemlerinin geliştirilmesini gerekli kılmaktadır.

Bu çalışmada ele alınan temel problem, akciğer X-ray görüntülerinden COVID-19 hastalığının yapay zekâ yöntemleri kullanılarak otomatik olarak tespit edilmesidir. Bu problem bir görüntü sınıflandırma problemi olarak ele alınmaktadır.

1.2. Çalışmanın Amacı

Bu çalışmanın temel amacı, akciğer X-ray görüntülerini kullanarak COVID-19 hastalığını yüksek doğruluk oranı ile tespit edebilen bir sistem geliştirmektir.

Bu kapsamda aşağıdaki hedefler belirlenmiştir:

- Literatürde yer alan çalışmaların incelenmesi
- En başarılı derin öğrenme modellerinin belirlenmesi
- Seçilen modellerin veri seti üzerinde uygulanması
- Farklı yöntemlerin performanslarının karşılaştırılması
- En uygun modelin belirlenmesi

1.3. Çalışmanın Kapsamı

Bu çalışma kapsamında COVID-19, normal ve pnömoni sınıflarına ait akciğer X-ray görüntüleri kullanılarak sınıflandırma işlemi gerçekleştirilecektir. Çalışmada derin öğrenme ve hibrit yaklaşımlar kullanılacak olup veri ön işleme, model eğitimi ve performans değerlendirme aşamaları ele alınacaktır.

1.4. Kabuller ve Sınırlılıklar

Kabuller:

- Veri setinde yer alan COVID-19, Normal ve Pnömoni etiketlerinin uzman radyologlar tarafından hatasız şekilde yapıldığı ve "doğru veri" (ground truth) olduğu kabul edilmiştir.
- Görüntülerle birlikte sunulan akciğer maskelerinin (lung masks) anatomik sınırları doğru çizdiği ve segmentasyon işlemleri için yeterli hassasiyete sahip olduğu varsayılmıştır.

Sınırlılıklar:

- **Donanım Kısıtı:** Model eğitimi, kullanılan bilgisayarın GPU (grafik işlemci) ve RAM kapasitesiyle sınırlıdır. Bu durum, çok derin ağların eğitilmesini veya çok yüksek "epoch" sayılarına çıkılmasını kısıtlamaktadır.
- **Görüntü Çözünürlüğü:** Sistem, veri setinin standart boyutu olan 299x299 (veya orijinal 1024x1024) piksel çözünürlüğe göre optimize edilmiştir. Farklı çözünürlükteki görüntülerde performans kaybı yaşanabilir.
- **Veri Çeşitliliği:** Çalışma, sadece veri setinde bulunan dört ana sınıfın (COVID-19, Normal, Akciğer Opasitesi ve Viral Pnömoni) ayırt edilmesiyle sınırlıdır, nadir görülen diğer akciğer hastalıklarını kapsamamaktadır.

2. LİTERATÜR TARAMASI

Bu bölümde, akciğer X-ray görüntüleri üzerinden COVID-19 ve diğer akciğer patolojilerinin tespiti üzerine yapılan güncel çalışmalar metodolojik yaklaşımlarına göre incelenmiştir ve okunan makaleler dört ana başlık altında (amacı, kullanılan veri seti, metodolojileri ve deney sonuçları) incelenip raporlanmış ve sonrasında birbiri ile kıyaslanmıştır.

2.1. Makale İncelemeleri

[1] Cutting-Edge Bayesian Deep Learning And Statistical Strategies For Bias Mitigation In Covid-19 Detection Via Chest X-Ray Imaging (2026)

- **Amaç:** COVID-19 tespitinde sıkça karşılaşılan veri seti yanlılığı (bias) ve etiket gürültüsü problemlerini çözmeyi hedeflemektedir.
- **Veri Seti:** 100'ü COVID-19 olmak üzere toplam 1531 adet X-ray görüntüsü kullanılmıştır.
- **Metodoloji:** Çalışmada zatürre verileriyle ön eğitilmiş (transfer learning) bir model kullanılarak başarı artırılmıştır. Akciğer segmentasyonu, segmentasyon rehberliğinde sınıflandırma, kalibre edilmiş topluluk öğrenmesi (ensembling) ve belirsizlik tahmini aşamalarından oluşan hibrit bir Bayesyen çerçevesi önerilmiştir. Ayrıca modelin dayanıklılığı (robustness) çeşitli görüntü bozulmalarıyla test edilmiştir.
- **Sonuç:** Önerilen yöntem %98.33 doğruluk oranına ulaşmıştır. Çalışma, transfer learning ve hibrit yaklaşımların sınırlı veri setlerinde bile yüksek güvenilirlik sunduğunu kanıtlamıştır.

[2] Exploring The Effect Of Image Enhancement Techniques On Covid-19 Detection Using Chest X-Ray Images (2021)

- **Amaç:** Farklı görüntü iyileştirme taktiklerinin derin öğrenme modellerinin teşhis performansına katkısını analiz etmektir.
- **Veri Seti:** Literatürdeki halka açık en büyük veri setlerinden biri (COVID-19 Radiography Database) kullanılmıştır.
- **Metodoloji:** Akciğer segmentasyonu için modifiye edilmiş bir U-Net mimarisi tercih edilmiştir. Modellerin karar mekanizmasını açıklanabilir kılmak adına **Score-CAM** tabanlı ısı haritaları (Explainable AI - xAI) kullanılarak, modelin akciğerin hangi bölgelerine odaklandığı görselleştirilmiştir.
- **Sonuç:** X-ışını görüntü iyileştirme tekniklerinin başarıyı en çok artıran faktör olduğu belirlenmiştir. Doğru segmentasyonun ve açıklanabilir yapay zeka yaklaşımlarının, klinik güvenilirlik açısından kritik öneme sahip olduğu vurgulanmıştır.

[3] Ai-Powered Diagnosis Of Respiratory Diseases: Evaluating Vision Transformers And Resnet Architectures For Covid-19 And Lung Pathologies (2025)

- **Amaç:** Solunum yolu hastalıklarının teşhisinde geleneksel CNN mimarileri ile modern Transformer yapılarını kıyaslamaktır.
- **Veri Seti:** 21.165 adet görüntüden oluşan geniş ölçekli bir veri seti üzerinde çalışılmıştır.
- **Metodoloji:** 2025 yılı güncel literatürünü yansıtan bu çalışmada, klasik ResNet (50, 101, 152) modelleri ile dikkat (attention) mekanizmasına dayalı Vizyon Transformer (ViT) mimarisi karşılaştırılmıştır. CNN'lerin yerel özellik çıkarma yeteneği ile ViT'in küresel bağlam kurma yeteneği analiz edilmiştir.
- **Sonuç:** ViT modeli, büyük veri setinde en yüksek doğruluk oranını sergilemiştir. Çalışma, dikkat mekanizmalarının tıbbi görüntü analizinde yeni standart haline geldiğini ortaya koymuştur.

[4] Can AI Help In Screening Viral And Covid-19 Pneumonia? (2020)

- **Amaç:** COVID-19 ve viral pnömoniye X-ray görüntülerinden hızlı ve doğru şekilde ayırt edebilecek, radyologların yükünü azaltacak sığ ve derin yapay zeka modelleri geliştirmek.
- **Veri Seti:** Kaggle ve GitHub gibi farklı kaynaklardan toplanan, radyologlar tarafından doğrulanmış geniş bir veri seti kullanılmıştır. Literatürde öne çıkan veri artırımı (data augmentation) teknikleri bu çalışmada kapsamlı şekilde uygulanmıştır.
- **Metodoloji:** Çalışmada hem sığ ağlar hem de 121 katmanlı CheXNet ve 201 katmanlı DenseNet201 gibi derin evrimsel sinir ağları (CNN) kullanılmıştır. Transfer öğrenmenin (transfer learning) büyük veri setlerindeki avantajları analiz edilmiştir.
- **Sonuç:** CheXNet ve DenseNet201 modelleri en yüksek başarıyı sergilemiştir. Deneylerde saptanan 3 hatalı etiketleme (opaklık nedeniyle COVID-19 ve viral pnömoni karışımı), radyologların bile zorlandığı vakalarda sistemin ne kadar hassas ve güvenilir olduğunu ortaya koymuştur.

[5] Akciğer X-Ray Görüntülerinden COVID-19 Tespitinde Hafif ve Geleneksel Evrimsel Sinir Ağ Mimarilerinin Karşılaştırılması (2021)

- **Amaç:** COVID-19'un hızlı ve doğru teşhisini sağlamak için derin öğrenme tabanlı modellerin performansını karşılaştırmak ve özellikle mobil cihazlarda çalışabilecek hafif mimarilerin klinik etkinliğini analiz etmek.
- **Veri Seti:** Toplam 11.293 adet görüntüden oluşan veri seti; COVID-19 (3.616), Normal (3.261), Akciğer opasitesi (2.911) ve Diğer pnömoni (1.505) sınıflarını içermektedir.
- **Metodoloji:** Transfer öğrenme yaklaşımıyla eğitilmiş dört farklı mimari (MobileNetV2, NASNetMobile, Xception ve DenseNet121) kullanılmıştır. Çalışmada özellikle sığ (hafif) ağlar ile derin ağların doğruluk ve işlem maliyeti dengesi kıyaslanmıştır.
- **Sonuç:** En yüksek başarı %92,16 ile DenseNet121 modelinde elde edilmiştir. Hafif bir model olan MobileNetV2'nin %91,78 doğruluk oranına ulaşması, sistemin düşük donanımlı mobil sağlık ünitelerinde kullanılabilirliğini kanıtlamıştır.

[6] COVID-19 Hastalarında Oral Kortikosteroid Tedavisinin, Klinik Seyir, Hastane Yatış ve Mortalite Üzerine Etkisi (2022)

- **Amaç:** Hafif-orta şiddette COVID-19 pnömonisi olan ve oksijen ihtiyacı bulunmayan hastalarda oral kortikosteroid kullanımının klinik seyir ve mortalite üzerindeki etkisini retrospektif olarak incelemek.
- **Veri Seti:** 18 yaş üstü, PCR pozitif, hafif-orta pnömoni bulgusu olan ve hastane kayıtlarından retrospektif olarak takip edilen 119 hasta verisi kullanılmıştır.
- **Metodoloji:** Hastalara uygulanan oral Dekametazon (8 mg) ve Metilprednizolon (32–40 mg) tedavileri sonrası; tekrar başvuru, hastaneye yatış, yoğun bakım ihtiyacı ve mortalite oranları istatistiksel olarak analiz edilmiştir.
- **Sonuç:** Tedavi grubunda %56 tekrar başvuru ve %12,6 hastane yatışı saptanmıştır. Oral kortikosteroidin bu hasta grubunda belirgin bir klinik avantaj sağlamadığı, erken dönem kullanımının rutin olarak önerilmemesi gerektiği sonucuna varılmıştır.

[7] X-Ray Görüntülerini Kullanarak Glcm Ve Derin Özniteliklerin Birleşimine Dayalı Covid-19 Sınıflandırılması (2022)

- **Amaç:** Teşhis başarısını artırmak için geleneksel görüntü işleme tekniklerinden olan doku analizi (texture analysis) ile derin öğrenme özniteliklerini birleştiren hibrit bir yaklaşım sunmak.
- **Veri Seti:** COVID-19, Normal, Viral Pnömoni ve Akciğer Opasitesi sınıflarından oluşan, farklı kaynaklardan derlenmiş göğüs röntgeni görüntüleri kullanılmıştır.
- **Metodoloji:** Hibrit bir öznitelik çıkarma süreci izlenmiştir: Görüntülerin doku bilgisi GLCM matrisleri ile, derin özellikleri ise DenseNet201 mimarisi ile çıkarılmıştır. Bu iki farklı veri yapısı birleştirilerek Destek Vektör Makineleri (SVM) üzerinden sınıflandırılmıştır.
- **Sonuç:** Hibrit model %99,2 doğruluk oranına ulaşmıştır. Çalışma, derin öğrenme ile geleneksel özniteliklerin kombinasyonunun, tek başına kullanılan yöntemlere göre çok daha stabil sonuçlar verdiğini göstermiştir.

[8] Derin Öğrenme Tabanlı Yaklaşımlarla Akciğer Röntgen Görüntüleri Üzerinden Covid-19 Ve Bakteri Kaynaklı Zatürrenin Otomatik Teşhisi (2024)

- **Amaç:** COVID-19 ile bakteriyel zatürreyi radyolojik olarak ayırt edebilen yüksek başarılı sistemler geliştirmek ve öznitelik seçimi yöntemlerinin işlem hızına etkisini ölçmek.
- **Veri Seti:** Her sınıftan 1500 adet olmak üzere toplam 4.500 X-ray görüntüsü (COVID-19, Bakteriyel Pnömoni, Sağlıklı) kullanılmıştır.
- **Metodoloji:** VGG19, ResNet50 ve DenseNet201 modelleri transfer öğrenme ile kullanılmış; ayrıca elde edilen yüksek boyutlu öznitelikler üzerinde "Feature Selection" (Öznitelik Seçimi) uygulanarak SVM ile sınıflandırma yapılmıştır.
- **Sonuç:** En yüksek doğruluk %99,2 ile ResNet50 modelinde görülmüştür. Öznitelik seçimi sayesinde sınıflandırma hızı doğruluk kaybı yaşanmadan 5 kat artırılarak gerçek zamanlı teşhis potansiyeli gösterilmiştir.

[9] Covid-19 Hastalarında Akut Solunum Sıkıntısı Sendromu Yönetimi (2021)

- **Amaç:** COVID-19 seyrinde gelişen en ağır komplikasyon olan ARDS'nin (Akut Solunum Sıkıntısı Sendromu) mekanizmasını açıklamak ve güncel klinik yönetim stratejilerini derlemek.
- **Veri Seti:** Deneysel bir veri seti yerine, pandemi sürecindeki klinik gözlemleri ve dünya genelindeki tedavi protokollerini içeren kapsamlı bir literatür taraması temel alınmıştır.
- **Metodoloji:** Hastalığın patofizyolojik evreleri, ventilasyon stratejileri (prone pozisyonu vb.) ve yoğun bakım yönetimindeki kritik müdahaleler tıbbi literatür ışığında değerlendirilmiştir.
- **Sonuç:** COVID-19 kaynaklı ARDS'nin hızla ilerleyen bir tablo olduğu, erken teşhisin ve doğru yoğun bakım yönetiminin mortaliteyi azaltmada en kritik faktör olduğu vurgulanmıştır.

2.2. İleri Seviye Derin Öğrenme ve Güvenilirlik Stratejileri

Literatürdeki en güncel yaklaşımlar, modellerin sadece performansına değil, aynı zamanda kararların güvenilirliğine odaklanmaktadır. [1] numaralı çalışmada, veri seti yanlılığını gidermek amacıyla Bayesian çerçevesi ve akciğer segmentasyonu birleştirilerek %98,33 doğruluk elde edilmiştir. Görüntü kalitesinin modele etkisini inceleyen [2] numaralı çalışmada ise, görüntü iyileştirme tekniklerinin başarısı ve xAI (Score-CAM) ile modelin odaklandığı bölgelerin görselleştirilmesi sağlanmıştır. 2025 yılına ait bir başka güncel çalışma olan [3], Vision Transformers (ViT) ile ResNet mimarilerini karşılaştırarak modern dikkat (attention) mekanizmalarının küresel öznitelik çıkarma başarısını incelemiştir.

2.3. Evrimsel Sinir Ağları (CNN) ve Transfer Öğrenme Yaklaşımları

CNN mimarileri, bu alanın standart çözümü olmaya devam etmektedir. Literatürde "altın standart" kabul edilen çalışmalardan biri olan [4], CheXNet ve DenseNet201 modellerini veri artırımı ile eğiterek radyolog düzeyinde teşhis başarısı sergilemiş, sistemin opaklık nedeniyle oluşan hatalı etiketlemelerde bile güçlü durduğunu göstermiştir. [5] numaralı çalışmada ise MobileNetV2 ve DenseNet121 mimarileri kıyaslanmış, hafif modellerin mobil sağlık üniteleri için uygunluğu kanıtlanmıştır. Benzer şekilde, [8] numaralı çalışmada ResNet50 mimarisi kullanılarak %99,2 gibi çok yüksek bir doğruluk oranına ulaşılmıştır.

2.4. Hibrit Yöntemler ve Doku Analizi

Sadece derin özniteliklerle yetinmeyip, geleneksel öznitelik çıkarma yöntemlerini (handcrafted features) DL ile birleştiren hibrit çalışmalar dikkat çekmektedir. [7] numaralı

çalışmada, GLCM matrisleri ile elde edilen doku özellikleri DenseNet201'den gelen derin özniteliklerle birleştirilerek SVM üzerinden sınıflandırılmıştır. [8] numaralı çalışma da benzer şekilde öznitelik seçimi (feature selection) yöntemlerini kullanarak teşhis hızını doğruluk kaybı yaşamadan 5 kat artırmayı başarmıştır.

2.5. Klinik Perspektif ve Komplikasyon Yönetimi

Teşhis sistemlerinin başarısı kadar, hastalığın klinik seyri de literatürde kritik bir yer tutmaktadır. [6] numaralı retrospektif analiz, kortikosteroid tedavisinin hafif-orta vakalardaki sınırlı etkisini incelerken; [9] numaralı derleme çalışması, COVID-19'un en ağır tablosu olan Akut Solunum Sıkıntısı Sendromu (ARDS) yönetimine dair teorik bir çerçeve sunarak modellerin klinik entegrasyonu için gerekli tıbbi arka planı sağlamıştır.

2.6. Literatürün Genel Değerlendirmesi ve Sentezi

İncelenen çalışmalar kronolojik ve metodolojik olarak değerlendirildiğinde; COVID-19 teşhisinde evrimin geleneksel CNN mimarilerinden [4, 5], daha karmaşık ve dikkat (attention) mekanizmalı yapılara [3] doğru ilerlediği gözlemlenmiştir. Literatürde, özellikle veri seti kısıtlılığına karşı **transfer öğrenme (Transfer Learning)** ortak bir çözüm olarak benimsenmiştir. Ancak, Chen vd. [1] tarafından vurgulanan 'veri seti yanlılığı' (bias) sorunu, çalışmalarda sadece doğruluğun değil, Bayesian yaklaşımlar gibi istatistiksel güvenilirliğin de önemini ortaya koymuştur. Öte yandan Nasip [8] ve Hayıt vd. [7] tarafından önerilen hibrit yaklaşımlar, derin özelliklerin geleneksel doku analiziyle birleştirilmesinin, hesaplama maliyeti ile doğruluk arasında bir denge kurduğunu kanıtlamıştır. Bu sentez ışığında projemiz; geleneksel (Otsu), hibrit (SVM) ve derin öğrenme (DenseNet) metodolojilerini birleştirerek literatürdeki bu farklı yaklaşımların performansını aynı veri seti üzerinde test etmeyi amaçlamaktadır.


2.7. Literatür Sentez Tablosu

Aşağıdaki tablo, incelenen 9 çalışmanın temel teknik parametrelerini ve elde edilen sonuçları karşılaştırmalı olarak sunmaktadır:

No	Kaynak (Yazar / Yıl)	Yöntem Mimari	Veri Seti Boyutu	Temel Sonuç
[1]	Chen vd. (2026)	Bayesian DL + Segmentasyon	1.531	%98,33 Acc. / Bias Giderme
[2]	Rahman vd. (2021)	U-Net + Score-CAM (xAI)	21.165	İyileştirme & Açıklanabilirlik
[3]	Solak (2025)	ViT vs. ResNet (50, 101, 152)	21.165	Attention Mekanizması Üstünlüğü
[4]	Chowdhury vd. (2020)	CheXNet & DenseNet201	Büyük Ölçek	Radyolog Düzeyinde Teşhis
[5]	Eryılmaz vd. (2021)	MobileNetV2 vs DenseNet121	11.293	%92,16 Acc. / Mobil Uyumluluk
[6]	Balcı vd. (2022)	Klinik Retrospektif Analiz	119 Hasta	Kortikosteroid Etkinliği Analizi
[7]	Hayıt vd. (2022)	GLCM + DenseNet201 (Hibrit)	Belirtilmemiş	%99,2 Acc. / Dokusal Başarı
[8]	Nasip (2024)	ResNet50 + SVM + Feat. Sel.	4.500	%99,2 Acc. / 5 Kat Hız Artışı
[9]	Karabacak vd. (2021)	Derleme (Review)	-	ARDS ve Patofizyoloji Yönetimi

3. METODOLOJİ

Önerilen sistemin genel çalışma mimarisi ve veri akış süreci Şekil 1'de sunulmuştur.



Şekil 1: COVID-19 Teşhis Sistemi İş Akış Şeması

3.1. Veri Seti Tanımı ve Hazırlığı

Bu çalışmada, literatürde yaygın olarak kullanılan ve [2,4] numaralı çalışmalarda detaylandırılan "COVID-19 Radiography Database" kullanılmıştır. Veri seti; 3.616 COVID-19, 10.192 Normal, 6.012 Akciğer Opasitesi ve 1.345 Viral Pnömoni görüntüsü olmak üzere toplam 21.165 X-ray görüntüsünden oluşmaktadır. Ayrıca her görüntüye ait akciğer maskelerinin (lung masks) bulunması, segmentasyon tabanlı analizleri olanaklı kılmaktadır.

Kullanılan veri seti, yüksek düzeyde standardize edilmiş meta-verilere ve tam dokümantasyona sahiptir (Kaggle Usability Score = 10.0). Veri setinin yapısal tutarlılığı, ön işleme (preprocessing) ve gürültü giderme aşamalarının daha efektif bir şekilde yürütülmesine olanak tanımaktadır. Veri seti kaynaklarının detaylı atıfları için Ek.1 incelenebilir.

3.2. Önerilen Yöntemler

Proje kapsamında geliştirilecek olan sistem, düşük karmaşıklıktan yüksek başarımlı modellere uzanan üç farklı hiyerarşik yapıdan oluşmaktadır:

1. **Baseline (Traditional Image Processing):** Lung maskeler kullanılarak izole edilen akciğer alanları üzerinde **Otsu's Thresholding** algoritması uygulanacaktır. Bu aşamada, bi-modal histogram dağılımı üzerinden *intra-class variance* minimize edilerek patolojik yoğunluklar (opasite) tespit edilecektir.
2. **Machine Learning (Feature-Based):** Görüntülerden öznelik çıkarımı (feature extraction) için **HOG (Histogram of Oriented Gradients)** ve **LBP (Local Binary Patterns)** algoritmaları hibrit olarak kullanılacaktır. Elde edilen vektörler, yüksek boyutlu uzayda sınıflandırma yapabilen **SVM (Support Vector Machine)** ile işlenecektir.
3. **Deep Learning (Transfer Learning):** Literatürde başarısı kanıtlanmış olan **DenseNet-201** mimarisi kullanılacaktır. Model, ImageNet üzerinde ön-eğitilmiş (pre-trained) ağırlıklar ile başlatılacak ve veri setimizdeki 21.165 görüntü ile *fine-tuning* işlemine tabi tutulacaktır.

3.3. Performans Değerlendirme Metrikleri (Evaluation Metrics)

Modellerin başarısını ölçmek için kullanılan temel metriklerin matematiksel ifadeleri şu şekildedir:

- **Accuracy (Doğruluk):** Sistemin genel doğru tahmin oranını gösterir.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Sensitivity / Recall (Duyarlılık):** Gerçek pozitif vakaların ne kadarının doğru tespit edildiğini ölçer (Tıbbi teşhiste en kritik metrik).

$$Sensitivity = \frac{TP}{TP + FN}$$

- **Precision (Kesinlik):** Pozitif tahminlerin ne kadarının gerçekten doğru olduğunu gösterir.

$$Precision = \frac{TP}{TP + FP}$$

- **F1-Score:** Precision ve Recall değerlerinin dengeli bir dağılımını sunar.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Notasyon Tanımları:

- **TP (True Positive):** COVID-19 olan hastanın doğru şekilde "COVID-19" olarak tahmin edilmesi.
- **TN (True Negative):** Sağlıklı bireyin doğru şekilde "Normal" olarak tahmin edilmesi.
- **FP (False Positive):** Sağlıklı bireyin yanlışlıkla "COVID-19" olarak tahmin edilmesi (Hatalı alarm).
- **FN (False Negative):** COVID-19 olan hastanın yanlışlıkla "Normal" olarak tahmin edilmesi (**Klinik risk!**).

4. KAYNAKÇA

- [1] Y. Chen vd., "Cutting-edge bayesian deep learning and statistical strategies for bias mitigation in COVID-19 detection via chest x-ray imaging," *Scientific Reports*, cilt 16, no. 112, 2026.
- [2] T. Rahman vd., "Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images," *Computers in Biology and Medicine*, cilt 132, s. 104319, 2021.
- [3] A. Solak, "AI-powered diagnosis of respiratory diseases: Evaluating vision transformers and ResNet architectures for covid-19 and lung pathologies," *Niğde Ömer Halisdemir University Journal of Engineering Sciences*, cilt 14, no. 4, ss. 1385-1397, 2025.
- [4] M. E. H. Chowdhury vd., "Can AI help in screening Viral and COVID-19 pneumonia?" *IEEE Access*, cilt 8, ss. 132665 - 132676, 2020.
- [5] F. Eryılmaz ve H. Karacan, "Akciğer X-Ray Görüntülerinden COVID-19 Tespitinde Hafif ve Geleneksel Evrişimsel Sinir Ağ Mimarilerinin Karşılaştırılması," *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, cilt 9, ss. 26-39, 2021.
- [6] U. Balcı vd., "COVID-19 Hastalarında Oral Kortikosteroid Tedavisinin, Klinik Seyir, Hastane Yatış ve Mortalite Üzerine Etkisi," *Van Tıp Dergisi*, cilt 29, no. 3, ss. 290-296, 2022.
- [7] T. Hayıt ve G. Çınarer, "X-RAY GÖRÜNTÜLERİNİ KULLANARAK GLCM VE DERİN ÖZNİTELİKLERİN BİRLEŞİMİNE DAYALI COVID-19 SINIFLANDIRILMASI," *İnönü Üniversitesi Sağlık Hizmetleri Meslek Yüksekokulu Dergisi*, cilt 10, no. 1, ss. 313-325, 2022.
- [8] Ö. F. Nasip, "Derin öğrenme tabanlı yaklaşımlarla akciğer röntgen görüntüleri üzerinden COVID-19 ve bakteri kaynaklı zatürrenin otomatik teşhisi," *Gümüşhane Üniversitesi Fen Bilimleri Dergisi*, cilt 14, no. 4, ss. 1161-1176, 2024.
- [9] P. Karabacak ve P. Kırdemir, "COVID-19 HASTALARINDA AKUT SOLUNUM SIKINTISI SENDROMU YÖNETİMİ," *SDÜ Tıp Fakültesi Dergisi*, cilt 28, Özel Sayı 1, ss. 51-56, 2021.

EKLER

EK 1. Veri Seti Kaynakları ve Teknik Spesifikasyonlar

EK 1. Veri Seti Kaynakları ve Teknik Spesifikasyonlar

Bu ek bölümde, çalışmada kullanılan "COVID-19 Radiography Database" içeriğinin derlendiği ham veri depoları ve teknik parametreler sunulmaktadır. Veri setinin ana akademik atıfları "Kaynakça" bölümünde yer almakla birlikte, şeffaflık ve çalışmanın yeniden üretilebilirliği adına kaynak havuzları aşağıda kategorize edilmiştir.

1.1. Veri Seti İçin Zorunlu Akademik Atıflar

Veri setinin kullanım kuralları gereği, aşağıda belirtilen iki temel çalışma metodolojik referans olarak kabul edilmiştir:

- [9] M.E.H. Chowdhury, T. Rahman, A. Khandakar, R. Mazhar, M.A. Kadir, Z.B. Mahbub, K.R. Islam, M.S. Khan, A. Iqbal, N. Al-Emadi, M.B.I. Reaz, M. T. Islam, “Can AI help in screening Viral and COVID-19 pneumonia?” IEEE Access, Vol. 8, 2020, pp. 132665 - 132676.
- [7] Rahman, T., Khandakar, A., Qiblawey, Y., Tahir, A., Kiranyaz, S., Kashem, S.B.A., Islam, M.T., Maadeed, S.A., Zughaier, S.M., Khan, M.S. and Chowdhury, M.E., 2020. Exploring the Effect of Image Enhancement Techniques on COVID-19 Detection using Chest X-ray Images. arXiv preprint arXiv:2012.02238.

1.2. Ham Veri Depoları ve Kaynak Linkler

Derleme veri setini oluşturan alt havuzların dijital erişim adresleri şunlardır:

No	Veri Deposu / Proje Adı	Erişim Linki
1	BIMCV-COVID19	Erişim Adresi
2	ML Workgroup (GitHub)	Erişim Adresi
3	SIRM (Società Italiana di Radiologia Medica)	Erişim Adresi
4	EuroRad	Erişim Adresi

5	IEEE COVID-19 Dataset	Eriřim Adresi
6	Figshare Repository	Eriřim Adresi
7	COVID-CXNet	Eriřim Adresi
8	RSNA Pneumonia Detection	Eriřim Adresi
9	Chest X-Ray Pneumonia (P. Mooney)	Eriřim Adresi

1.3. Teknik Veri Özellikleri

Veri setindeki görüntüler üzerinde yapılacak sayısal görüntü işleme adımları için řu teknik kısıtlar dikkate alınmıřtır:

- **Format:** Portable Network Graphics (PNG)
- **Çözünürlük:** 299 x 299 piksel (standardize edilmiř boyut)
- **Segmentasyon Desteęi:** Tüm görüntüler için radyolog onaylı akcięer maskeleri (lung masks) mevcuttur.
- **Amacı:** COVID-19, Viral Pnömoni ve Normal akcięer bulgularının ayırt edilmesine yönelik yapay zeka modellerinin eğitilmesi ve doęrulanması.